

Pontificia Universidad Javeriana.



Pontificia Universidad
JAVERIANA
Colombia

Cluster Apache Hadoop HDFS

Presentado Por: Marianne Coy, Daniel Diaz, Ricardo Hurtado, Samuel Giraldo y Jose Guerrero

8 de Mayo. 2026

1 Introducción

El presente informe describe el proceso de configuración de un clúster Apache Hadoop HDFS utilizando máquinas virtuales. HDFS, o Hadoop Distributed File System, es el sistema de archivos distribuido de Hadoop, diseñado para almacenar grandes volúmenes de información dividiéndola en bloques y distribuyéndola entre varios nodos del clúster.

La práctica permitió comprender la arquitectura maestro-esclavo de HDFS, donde un nodo principal, llamado NameNode, administra los metadatos del sistema de archivos, mientras que los DataNodes almacenan físicamente los bloques de datos. Esta configuración permite tolerancia a fallos, distribución de carga y almacenamiento escalable.

Según la documentación oficial de Apache Hadoop, HDFS está diseñado para almacenar archivos grandes en clústeres de máquinas, dividiendo los archivos en bloques y replicándolos para mejorar la disponibilidad y la tolerancia a fallos.

2 Objetivos

1.1 Objetivo general

Configurar un clúster HDFS con máquinas virtuales, verificando la comunicación entre los nodos y el correcto funcionamiento de los servicios principales de Hadoop.

1.2 Objetivo Especifico

- Configurar las máquinas virtuales necesarias para el clúster.
- Instalar Java y Apache Hadoop en cada nodo.
- Configurar los archivos principales de Hadoop: core-site.xml, hdfs-site.xml, workers y variables de entorno.
- Establecer comunicación SSH entre los nodos.
- Inicializar y ejecutar los servicios HDFS.
- Verificar el funcionamiento del clúster mediante comandos y la interfaz web de Hadoop.

3 Descripción del clúster implementado

Para el desarrollo del taller se configuró un clúster HDFS compuesto por tres máquinas virtuales:

Nodo	Rol	Función
master	NameNode	Administra los metadatos y coordina el sistema HDFS
worker1	DataNode	Almacena bloques de datos

worker2	DataNode	Almacena bloques de datos
---------	----------	---------------------------

El nodo master actúa como nodo principal del clúster. Los nodos worker1 y worker2 funcionan como nodos de almacenamiento. Esta distribución permite simular una arquitectura básica de Hadoop HDFS en un entorno virtualizado.

4 Pasos realizados

```
estudiante@MIG199:~$ cd /
estudiante@MIG199:/$ cd Almacen/
estudiante@MIG199:/Almacen$ ls
evalMxM_MPI  hadoop  hadoop-3.3.6.tar.gz  Taller04  Taller04.zip  TallerEvaluacionMPI.zip
estudiante@MIG199:/Almacen$ git clone https://github.com/RicardoHurtadoF/Servidor-Apache-Hadoop.git
cd Servidor-Apache-Hadoop
Command 'git' not found, but can be installed with:
sudo apt install git
-bash: cd: Servidor-Apache-Hadoop: No such file or directory
estudiante@MIG199:/Almacen$ sudo apt install git
```

Copiar repositorio para tener los codigos de configuracion

```
estudiante@MIG199:/Almacen$ git clone https://github.com/RicardoHurtadoF/Servidor-Apache-Hadoop.git
Cloning into 'Servidor-Apache-Hadoop'...
remote: Enumerating objects: 21, done.
remote: Counting objects: 100% (21/21), done.
remote: Compressing objects: 100% (19/19), done.
remote: Total 21 (delta 4), reused 0 (delta 0), pack-reused 0 (from 0)
Receiving objects: 100% (21/21), 8.71 KiB | 8.71 MiB/s, done.
Resolving deltas: 100% (4/4), done.
estudiante@MIG199:/Almacen$ cd Servidor-Apache-Hadoop
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ |
```

Anotar las ip de los nodos y su rol en el directorio /etc/hosts

```
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ sudo nano /etc/hosts
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ cat /etc/hosts
127.0.0.1    localhost
127.0.1.1    2530Ubuntu22

# The following lines are desirable for IPv6 capable hosts
::1        ip6-localhost ip6-loopback
fe00::0    ip6-localnet
ff00::0    ip6-mcastprefix
ff02::1    ip6-allnodes
ff02::2    ip6-allrouters

10.43.99.140 master
10.43.99.126 worker1
10.43.99.109 worker2

estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ |
```

se ejecuta el setup en todas las maquinas

```
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ chmod +x setup_hadoop.sh
./setup_hadoop.sh
Hit:1 http://co.archive.ubuntu.com/ubuntu jammy InRelease
Hit:2 http://co.archive.ubuntu.com/ubuntu jammy-updates InRelease
Hit:3 http://co.archive.ubuntu.com/ubuntu jammy-backports InRelease
Hit:4 http://security.ubuntu.com/ubuntu jammy-security InRelease
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
34 packages can be upgraded. Run 'apt list --upgradable' to see them.
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
rsync is already the newest version (3.2.7-0ubuntu0.22.04.4).
wget is already the newest version (1.21.2-2ubuntu1.1).
openjdk-8-jdk is already the newest version (8u482-ga~us1-0ubuntu1~22.04).
ssh is already the newest version (1:8.9p1-3ubuntu0.15).
0 upgraded, 0 newly installed, 0 to remove and 34 not upgraded.
Instalación base completada
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ |
```

Se comprueba la conexión

```
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ ping worker1
PING worker1 (10.43.99.126) 56(84) bytes of data.
64 bytes from worker1 (10.43.99.126): icmp_seq=1 ttl=64 time=0.415 ms
64 bytes from worker1 (10.43.99.126): icmp_seq=2 ttl=64 time=0.467 ms
64 bytes from worker1 (10.43.99.126): icmp_seq=3 ttl=64 time=0.461 ms
64 bytes from worker1 (10.43.99.126): icmp_seq=4 ttl=64 time=0.503 ms
64 bytes from worker1 (10.43.99.126): icmp_seq=5 ttl=64 time=0.388 ms
64 bytes from worker1 (10.43.99.126): icmp_seq=6 ttl=64 time=0.476 ms
^C
--- worker1 ping statistics ---
6 packets transmitted, 6 received, 0% packet loss, time 5121ms
rtt min/avg/max/mdev = 0.388/0.451/0.503/0.038 ms
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ |
```

- sudo passwd hadoop
 - En los 3 para dejar una clave sencilla

```

(estudiante@MIG148:~/Downloads/Servidor-Apache-Hadoop$ sudo passwd hadoop
New password:
Retype new password:
passwd: password updated successfully
(estudiante@MIG148:~/Downloads/Servidor-Apache-Hadoop$ ssh hadoop@worker
ssh: Could not resolve hostname worker: Temporary failure in name resolution
(estudiante@MIG148:~/Downloads/Servidor-Apache-Hadoop$ ssh hadoop@worker1
The authenticity of host 'worker1 (10.43.99.126)' can't be established.
ED25519 key fingerprint is SHA256:t0BBEm+k74mXtMqOp1f5SkTV+HPXSZxtCwmGunc3ao.
This host key is known by the following other names/addresses:
  ~/.ssh/known_hosts:1: [hashed name]
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
Warning: Permanently added 'worker1' (ED25519) to the list of known hosts.
hadoop@worker1's password:
Welcome to Ubuntu 22.04.5 LTS (GNU/Linux 6.8.0-94-generic x86_64)

 * Documentation:  https://help.ubuntu.com
 * Management:    https://landscape.canonical.com
 * Support:        https://ubuntu.com/pro

Expanded Security Maintenance for Applications is not enabled.

42 updates can be applied immediately.
5 of these updates are standard security updates.
To see these additional updates run: apt list --upgradable

8 additional security updates can be applied with ESM Apps.
Learn more about enabling ESM Apps service at https://ubuntu.com/esm

New release '24.04.4 LTS' available.
Run 'do-release-upgrade' to upgrade to it.

*** System restart required ***

The programs included with the Ubuntu system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.

Ubuntu comes with ABSOLUTELY NO WARRANTY, to the extent permitted by
applicable law.

To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.

(estudiante@MIG148:~/Downloads/Servidor-Apache-Hadoop$ sudo passwd hadoop
New password:
Retype new password:
passwd: password updated successfully
(estudiante@MIG148:/Almacen/Servidor-Apache-Hadoop$ ssh hadoop@worker2
The authenticity of host 'worker2 (10.43.99.100)' can't be established.
ED25519 key fingerprint is SHA256:t0BBEm+k74mXtMqOp1f5SkTV+HPXSZxtCwmGunc3ao.
This host key is known by the following other names/addresses:
  ~/.ssh/known_hosts:1: [hashed name]
  ~/.ssh/known_hosts:4: [hashed name]
  ~/.ssh/known_hosts:5: [hashed name]
  ~/.ssh/known_hosts:9: [hashed name]
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
Warning: Permanently added 'worker2' (ED25519) to the list of known hosts.
hadoop@worker2's password:
Welcome to Ubuntu 22.04.5 LTS (GNU/Linux 6.8.0-94-generic x86_64)

 * Documentation:  https://help.ubuntu.com
 * Management:    https://landscape.canonical.com
 * Support:        https://ubuntu.com/pro

Expanded Security Maintenance for Applications is not enabled.

37 updates can be applied immediately.
To see these additional updates run: apt list --upgradable

5 additional security updates can be applied with ESM Apps.
Learn more about enabling ESM Apps service at https://ubuntu.com/esm

New release '24.04.4 LTS' available.
Run 'do-release-upgrade' to upgrade to it.

*** System restart required ***

The programs included with the Ubuntu system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.

Ubuntu comes with ABSOLUTELY NO WARRANTY, to the extent permitted by
applicable law.

To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.

```

```

chmod +x setup_master.sh
./setup_master.sh

```

```

bash: line 22: hdfs: command not found
bash: line 27: start-dfs.sh: command not found
bash: line 28: start-yarn.sh: command not found
Cluster iniciado

```

Si hay un error en el path de Hadoop

\usuario hadoop

```

estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ su - hadoop
Password:
To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.

hadoop@MIG199:~$ echo $HADOOP_HOME
/home/hadoop/hadoop

estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ export HADOOP_HOME=/Almacen/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ hdfs version
ERROR: JAVA_HOME is not set and could not be found.
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ nano ~/.bashrc
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ source ~/.bashrc
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ exec bash
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$ which hdfs
/Almacen/hadoop/bin/hdfs
estudiante@MIG199:/Almacen/Servidor-Apache-Hadoop$

```

Se añade al final de nano ~/.bashrc

```
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
export HADOOP_HOME=/Almacen/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
```

Ya habiendo hecho esto, se le da permisos a hadoop sobre el directorio:

```
hadoop@MIG199:~$ sudo chown -R hadoop:hadoop /Almacen/hadoop
[sudo] password for hadoop:
```

Ahora se inicia el servidor

```
hadoop@MIG199:~$ hdfs namenode -format
start-dfs.sh
2026-05-08 22:07:18,899 INFO namenode.NameNode: STARTUP_MSG:
/*****
STARTUP_MSG: Starting NameNode
STARTUP_MSG:   host = MIG199/10.43.99.140
STARTUP_MSG:   args = [-format]
STARTUP_MSG:   version = 3.3.6
*****/
/*****
SHUTDOWN_MSG: Shutting down NameNode at MIG199/10.43.99.140
*****/
Starting namenodes on [MIG199]
Starting datanodes
Starting secondary namenodes [MIG199]
hadoop@MIG199:~$ |
```

Se ejecuto

```

hadoop@MIG199:~$ cat > /Almacen/hadoop/etc/hadoop/core-site.xml <<EOF
<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://MIG199:9000</value>
  </property>
</configuration>
EOF

cat > /Almacen/hadoop/etc/hadoop/hdfs-site.xml <<EOF
<configuration>
  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>
</configuration>
EOF

hdfs namenode -format
start-dfs.sh

```

Se verifica que funcione con:

```

hadoop@MIG199:~$ jps
1095874 NameNode
1096923 SecondaryNameNode
1096380 DataNode
1097279 Jps

```

Se crea una carpeta de prueba

```

hadoop@MIG199:~$ hdfs dfs -mkdir /test
hdfs dfs -ls /
Found 1 items
drwxr-xr-x  - hadoop supergroup          0 2026-05-08 22:21 /test

```

5 Características del clúster HDFS

El clúster HDFS configurado presenta las siguientes características:

Primero, utiliza una arquitectura distribuida basada en un nodo principal y varios nodos de almacenamiento. El NameNode administra los metadatos del sistema, mientras que los DataNodes almacenan los bloques de datos. Esta arquitectura es característica de HDFS.

Segundo, permite la división de archivos en bloques. Cuando un archivo se almacena en HDFS, este se fragmenta en bloques que se distribuyen entre los DataNodes disponibles.

Tercero, cuenta con replicación de datos. En este caso se configuró un factor de replicación igual a 2, lo que significa que cada bloque puede tener dos copias en diferentes nodos. Esto mejora la tolerancia a fallos.

Cuarto, permite la tolerancia a fallos. Si uno de los DataNodes deja de funcionar, HDFS puede mantener la disponibilidad de los datos gracias a la existencia de réplicas.

Quinto, cuenta con monitoreo desde interfaz web. La interfaz del NameNode permite revisar el estado del clúster, los nodos activos, el almacenamiento usado y disponible, y la información general del sistema.

Sexto, permite escalabilidad horizontal. Es posible agregar más DataNodes al clúster para aumentar la capacidad de almacenamiento.

Séptimo, está diseñado para manejar grandes volúmenes de datos. HDFS fue creado para trabajar con archivos grandes y cargas de trabajo distribuidas, lo que lo hace útil en entornos de Big Data.

6 Observaciones

Durante la configuración del clúster fue importante verificar que todas las máquinas virtuales estuvieran en la misma red y pudieran comunicarse entre sí mediante ping.

También fue necesario configurar correctamente el archivo `/etc/hosts`, ya que Hadoop depende de la resolución de nombres entre los nodos.

La configuración SSH sin contraseña fue fundamental para que el nodo master pudiera iniciar los servicios en los nodos worker.

El comando `jps` fue útil para verificar si los servicios de Hadoop estaban activos en cada máquina.

Una posible dificultad durante la práctica es que los DataNodes no aparezcan activos en la interfaz web. Esto puede deberse a errores en la configuración de red, problemas con SSH, nombres de host incorrectos o rutas mal configuradas en `hdfs-site.xml`.

7 Conclusiones

- La configuración del clúster HDFS permitió comprender de manera práctica el funcionamiento de un sistema de archivos distribuido.
- Se evidenció que HDFS utiliza una arquitectura compuesta por un NameNode y varios DataNodes, donde el primero administra la información del sistema y los segundos almacenan los datos.

- La replicación de bloques es una característica fundamental de HDFS, ya que permite mejorar la disponibilidad de la información y reducir el riesgo de pérdida de datos ante fallos en los nodos.
- La práctica permitió identificar la importancia de la comunicación entre máquinas virtuales, la configuración de red, el acceso SSH y la correcta edición de los archivos de configuración de Hadoop.

Finalmente, se concluye que HDFS es una herramienta importante dentro del ecosistema Big Data porque permite almacenar grandes volúmenes de información de manera distribuida, escalable y tolerante a fallos.

8 Referencias

Apache Hadoop. (2023). *Apache Hadoop 3.3.6 – HDFS Architecture*. Apache Software Foundation.

Apache Hadoop. (s. f.). *HDFS Architecture Guide*. Apache Software Foundation.